

PROJETO: APLICAÇÃO DE MACHINE LEARNING CLÁSSICO

**PREVISÃO DE INADIMPLÊNCIA E DO VALOR EM RISCO EM
CLIENTES DE CARTÃO DE CRÉDITO USANDO MACHINE
LEARNING CLÁSSICO**

Tema 4.5: Default Credit Card, inadimplência e valor em risco

Alunos: Otávio Bonini e Cauã Medeiros

Professor: Rodrigo Ramos Silva

Disciplina: Machine Learning Clássico

2026

SUMÁRIO

1 INTRODUÇÃO, PROBLEMA E JUSTIFICATIVA.....	3
1.1 Contextualização do problema real.....	3
1.2 Definição do problema de Machine Learning.....	3
1.3 Justificativa e relevância.....	4
OBJETIVOS.....	5
1.3.1 Objetivo geral.....	5
1.3.2 Objetivos específicos.....	5
1.4 FUNDAMENTAÇÃO TEÓRICA.....	5
1.4.1 Revisão do domínio: risco de crédito.....	5
1.4.2 Referencial teórico em Machine Learning.....	6
1.5 METODOLOGIA E DESENVOLVIMENTO.....	8
1.5.1 Análise Exploratória de Dados (EDA).....	8
1.5.2 Pré-processamento e engenharia de atributos.....	9
1.5.3 Implementação, treinamento e otimização.....	10
1.5.4 Avaliação e análise de resultados.....	10
1.5.5 Conclusão, produto final e cronograma.....	14
REFERÊNCIAS.....	16

1 INTRODUÇÃO, PROBLEMA E JUSTIFICATIVA

1.1 Contextualização do problema real

Domínio de aplicação. O projeto trata de risco de crédito em cartões. É uma área do setor financeiro que envolve bancos, contabilidade e cobrança. O cartão de crédito é arriscado para o banco por um motivo simples: o dinheiro é liberado antes, sem garantia, e o limite fica sempre disponível. O banco só descobre que o cliente não vai pagar quando a fatura vence.

Situação atual. Hoje os bancos decidem quem é arriscado de três formas, e todas têm problema:

- Análise manual: um analista olha cliente por cliente. Funciona bem, mas é impossível fazer isso com centenas de milhares de clientes.
- Regras fixas, do tipo "bloquear quem atrasou 60 dias": são baratas, mas só agem depois que o prejuízo aconteceu. Além disso, olham uma condição de cada vez e não enxergam combinações.
- Score estatístico tradicional: melhor que os anteriores, mas só consegue captar relações simples e diretas entre as variáveis.

O custo do erro é desigual, e isso é o mais importante. Se o banco não percebe que o cliente vai dar calote, perde o dinheiro emprestado. Se o banco desconfia de um cliente bom, perde só um pouco de receita e irrita o cliente. O primeiro erro é muito mais caro que o segundo, e essa diferença orienta todas as decisões do trabalho.

Base teórica. Os números confirmam que o problema é real. A Serasa (2026) aponta 83,3 milhões de brasileiros inadimplentes em abril de 2026, metade da população adulta. O Banco Central (2026) registrou inadimplência de 7,8% no crédito livre para pessoas físicas em julho de 2026, o maior valor já medido. Na academia, Yeh e Lien (2009), autores da base usada neste trabalho, mostraram que estimar a probabilidade de calote é mais útil para controlar o risco do que só classificar o cliente em bom ou ruim.

1.2 Definição do problema de Machine Learning

Definição técnica. O projeto tem duas etapas:

1. Classificação binária: prever se o cliente vai ficar inadimplente no mês seguinte (sim ou não).
2. Regressão: estimar quanto dinheiro está em jogo com esse cliente, ou seja, o valor da fatura dele.

No fim, as duas são multiplicadas e viram uma única medida: o Valor em Risco, que é a probabilidade de calote vezes o valor exposto.

Variável alvo. Na classificação, é a coluna default payment next month, que renomeamos para inadimplente. Ela vale 1 se o cliente não pagou no mês seguinte e 0 se pagou.

Na regressão, é a coluna BILL_AMT1, o valor da fatura mais recente, que usamos como medida da exposição financeira.

Dataset escolhido. Usamos a base Default of Credit Card Clients, do UCI Machine Learning Repository (YEH; LIEN, 2009), disponível em <https://archive.ics.uci.edu/ml/datasets/default+of+credit+card+clients> e baixada pelo pacote ucimlrepo (id 350). São 30.000 clientes de um banco de Taiwan, com 23 características e o resultado (pagou ou não), cobrindo abril a setembro de 2005. Acesso em 17 de setembro de 2026.

Escolhemos essa base por quatro motivos. Ela tem ao mesmo tempo a informação de calote e os valores em dinheiro, o que permite fazer as duas etapas na mesma população. Tem seis meses de histórico, o que permite criar indicadores de comportamento. Tem desbalanceamento realista, com cerca de 22% de inadimplentes. E não tem nenhum dado faltando.

1.3 Justificativa e relevância

Impacto. O modelo transforma uma lista solta de clientes em uma fila ordenada por quanto dinheiro está em risco. Com isso, a equipe de cobrança, que não consegue ligar para todo mundo, liga primeiro para quem realmente importa. Ganha-se em três frentes: a operação foca onde tem retorno, a contabilidade consegue prever melhor as perdas, e o banco pode renegociar antes do calote em vez de cobrar depois.

Relevância do Machine Learning. Por que não resolver isso com regras simples? Por três razões.

A primeira é que o risco vem da combinação das características, não de uma isolada. Dois meses de atraso significa uma coisa para quem tem limite alto e usa pouco, e outra bem diferente para quem já está endividado até o pescoço. Regra fixa não enxerga isso.

A segunda é que são 23 variáveis. O número de combinações possíveis é grande demais para alguém montar na mão.

A terceira, e mais importante: o modelo devolve uma probabilidade, não um simples sim ou não. É essa probabilidade que permite ordenar os clientes do mais para o menos arriscado, ajustar o nível de rigor conforme o custo do erro e multiplicar pelo valor da dívida para chegar a um número em reais. Nenhuma regra fixa faz isso.

Vale dizer que o modelo não substitui a política de crédito do banco nem o analista humano. Ele só organiza a fila de quem deve ser olhado primeiro.

OBJETIVOS

1.3.1 Objetivo geral

Desenvolver e comparar modelos de Machine Learning Clássico para prever o risco de inadimplência e estimar o valor financeiro exposto a esse risco em clientes de cartão de crédito, usando a base pública Default of Credit Card Clients.

1.3.2 Objetivos específicos

3. Obter e organizar a base, documentando a fonte e o significado de cada variável.
4. Fazer a Análise Exploratória de Dados (EDA), verificando dados faltantes, valores extremos, categorias estranhas e o desbalanceamento das classes.
5. Preparar os dados e criar novas colunas que resumam o comportamento de pagamento do cliente.
6. Treinar e ajustar dois modelos de classificação (Regressão Logística e Random Forest), priorizando Recall e F1-Score.
7. Comparar três modelos de regressão para estimar a exposição financeira.
8. Comparar os modelos no conjunto de teste e justificar as métricas escolhidas.
9. Verificar quais variáveis mais pesam na previsão.
10. Juntar as duas etapas no Valor em Risco e medir o ganho em relação a escolher clientes ao acaso.
11. Discutir as limitações e os riscos de usar esse modelo na prática.

1.4 FUNDAMENTAÇÃO TEÓRICA

1.4.1 Revisão do domínio: risco de crédito

a) Conceitos-chave

Inadimplência. É quando o cliente não paga nem o valor mínimo da fatura no vencimento. Na nossa base, o cliente é marcado como inadimplente se falhou no mês seguinte aos seis meses observados. É uma situação daquele mês, não um rótulo permanente.

Risco de crédito. É a chance de o banco perder dinheiro porque o cliente não pagou. Pelas regras de Basileia, a perda esperada se divide em três partes: PD, a probabilidade de o calote acontecer; EAD, o valor devido na hora do calote; e LGD, quanto disso o banco realmente não recupera. Neste projeto calculamos a PD (na classificação) e uma estimativa da EAD (na regressão). Não temos dados de LGD, então o resultado é o valor exposto ao risco, e não a perda real.

Crédito rotativo. É o que acontece quando o cliente paga menos que a fatura inteira e leva o resto para o mês seguinte, pagando juros. Quem faz isso todo mês tem risco alto de piorar.

Utilização do limite. É o quanto da fatura ocupa o limite disponível. Cliente que usa quase todo o limite, mês após mês, depende do crédito. Isso é sinal de risco, não de capacidade de pagar.

Credit scoring. É dar uma nota de risco ao cliente. Existe a nota da concessão, feita quando o cliente pede o cartão, e a nota de comportamento, refeita periodicamente com base no que ele faz. O nosso caso é o segundo: o cliente já tem cartão e queremos ver se o comportamento dele está piorando.

b) Estatísticas e fatos

- O Brasil tem 83,3 milhões de inadimplentes (abril de 2026), metade da população adulta, com R\$ 568 bilhões em dívidas atrasadas (SERASA, 2026).
- A inadimplência do crédito livre para pessoas físicas bateu recorde em julho de 2026, com 7,8% (BANCO CENTRAL DO BRASIL, 2026).
- Na base que usamos, 22,12% dos 30.000 clientes ficaram inadimplentes.
- Lessmann et al. (2015) testaram 41 modelos em oito bases de crédito. Entre os modelos individuais e os de conjunto simples, o Random Forest teve a melhor posição média no ranking (4,46), bem à frente da Regressão Logística (9,34).

c) Soluções sem Machine Learning e suas limitações

As regras fixas do banco (bloquear após tantos dias de atraso, negar aumento de limite para quem tem restrição) são fáceis de entender e de auditar. O problema é que agem só depois do prejuízo e avaliam uma condição por vez, sem enxergar combinações. E os números usados nessas regras normalmente vêm do costume, não de análise de dados.

Os sistemas especialistas, que transformam a experiência do analista em uma árvore de regras escrita à mão, dão muito trabalho para manter. Cada mudança na economia obriga a reescrever tudo.

O score estatístico tradicional, feito com regressão logística e poucas variáveis, foi um avanço grande e ainda é padrão em muitos bancos, porque é fácil de explicar. A limitação é que ele assume que tudo se comporta de forma linear, exige que o analista diga manualmente quais variáveis interagem entre si, e costuma jogar fora o histórico mês a mês. É aí que os modelos mais flexíveis ganham.

1.4.2 Referencial teórico em Machine Learning

Modelo A: Regressão Logística

A Regressão Logística soma as características do cliente, cada uma multiplicada por um peso, e passa o resultado por uma função que aperta tudo entre 0 e 1. O número que sai é a probabilidade de o cliente dar calote. Os pesos são aprendidos a partir dos exemplos de treino.

A grande vantagem é que dá para ler os pesos. Peso positivo quer dizer que a característica aumenta o risco, e peso negativo, que diminui. Por isso ela é o padrão nos bancos: a instituição precisa conseguir explicar ao cliente por que negou o crédito. A desvantagem é que ela só separa os grupos com uma linha reta. Se o risco depender de combinações entre variáveis, ela não percebe sozinha.

Árvore de Decisão

A Árvore de Decisão separa os clientes com perguntas de sim ou não, escolhendo em cada passo a pergunta que melhor divide quem paga de quem não paga. O resultado é uma regra que dá para ler, como "se atrasou mais de um mês e usa mais de 70% do limite, o risco é alto". Ela pega combinações naturalmente, mas é instável: muda bastante com pequenas mudanças nos dados, e se crescer sem limite acaba decorando os exemplos. É a peça básica do modelo seguinte.

Modelo B: Random Forest (modelo de conjunto)

O Random Forest treina centenas de árvores em vez de uma. Cada árvore recebe um sorteio diferente dos clientes e, a cada pergunta, só pode olhar algumas variáveis sorteadas. Como cada árvore erra de um jeito diferente, os erros tendem a se anular quando todas votam juntas, e o conjunto fica muito mais estável que qualquer árvore sozinha (BREIMAN, 2001).

Ele também informa quais variáveis mais pesaram nas decisões. O preço é perder a explicação simples: não existe uma regra única para mostrar ao cliente. Esse é o dilema clássico entre acertar mais e conseguir explicar.

Modelos de regressão

A Regressão Linear Múltipla traça a reta que passa mais perto de todos os pontos. A Regressão Polinomial acrescenta termos ao quadrado, permitindo curvas; como isso cria muitos termos, usamos a regularização Ridge, que segura os pesos para o modelo não exagerar. O Random Forest Regressor usa a mesma ideia das centenas de árvores, tirando a média em vez de votar.

Métricas

Na classificação, a Precision diz, entre os clientes que o modelo apontou como arriscados, quantos realmente deram calote. O Recall diz, entre os que de fato deram calote, quantos o modelo pegou. O F1 junta os dois numa nota só. O ROC-AUC mede se o modelo coloca os clientes na ordem certa de risco, sem depender do corte escolhido.

Na regressão, o MAE é o erro médio em dinheiro. O RMSE também mede erro, mas pesa muito mais os erros grandes. O R^2 diz quanto da variação o modelo consegue explicar.

1.5 METODOLOGIA E DESENVOLVIMENTO

Todo o projeto foi feito em Python, no Google Colab, com a biblioteca scikit-learn. A semente aleatória foi fixada em 42 em todas as etapas, então os resultados se repetem sempre que o notebook é executado.

1.5.1 Análise Exploratória de Dados (EDA)

Descrição. A base tem 30.000 linhas e 24 colunas, todas numéricas: o limite de crédito, quatro dados do cliente (sexo, escolaridade, estado civil e idade), dezoito colunas de histórico divididas em três séries de seis meses (situação de pagamento, valor da fatura e valor pago, de abril a setembro de 2005) e a coluna alvo. As colunas vêm com nomes X1 a X23 e foram renomeadas para nomes legíveis. A coluna PAY_0 virou PAY_1, porque a numeração original pula do 0 para o 2.

Valores ausentes. Nenhum. A base não tem nenhum dado faltando.


Linhas duplicadas. Existem 35 linhas repetidas. Olhando de perto, 60 das 70 linhas envolvidas são de cartões parados, com fatura e pagamento zerados nos seis meses. É natural que clientes diferentes fiquem idênticos nessa situação, e como a base não tem identificação do cliente, não dá para afirmar que são a mesma pessoa. Por isso foram mantidas. Elas representam apenas 0,12% da base.

Valores extremos. As colunas de dinheiro são muito desiguais. O limite vai de NT\$ 10.000 a NT\$ 1.000.000, com mediana de NT\$ 140.000. A fatura mais recente tem mediana de NT\$ 22.382, mas chega a NT\$ 964.511, e também tem valores negativos. Não removemos esses valores. O cliente com fatura muito alta não é erro, é justamente o de maior exposição, que o modelo precisa aprender a tratar. A fatura negativa significa crédito a favor do cliente, por ter pago a mais.

Categorias fora da documentação. A coluna de escolaridade tem os códigos 0, 5 e 6, e a de estado civil tem o código 0, que não aparecem na documentação da base. Como não dá para saber o que significam, removemos essas linhas. Saíram 399 clientes (1,33% da base), sobrando 29.601. A taxa de inadimplência passou de 22,12% para 22,31%, uma mudança pequena. Registramos o custo dessa decisão: os clientes removidos tinham só 7,8% de calote, então saiu mais gente boa do que ruim.

Desbalanceamento. 22,31% dos clientes deram calote. Isso é importante porque torna a acurácia uma métrica enganosa: um modelo que diz que ninguém vai dar calote acerta 77,7% e não serve para nada.

Figura 1: Distribuição do alvo e taxa de calote por nível de atraso



Fonte: elaborado pelos autores.

O gráfico da direita mostra a descoberta mais forte da análise: o atraso no mês mais recente já diz muito sozinho. Entre os clientes em dia, 16,9% deram calote. Com um mês de atraso, 34,2%. Com dois meses, 69,6%. Com três, 76,2%.

1.5.2 Pré-processamento e engenharia de atributos

Divisão dos dados. Separamos 80% dos clientes para treino (23.680) e 20% para teste (5.921). O teste funciona como uma prova que o modelo nunca viu: ele só é usado no final, para medir se o modelo aprendeu de verdade ou só decorou. A divisão foi estratificada, ou seja, os 22% de inadimplentes aparecem na mesma proporção nos dois lados. Para ajustar os modelos, usamos validação cruzada em 5 partes, sempre dentro do treino.

Dados ausentes. Não houve tratamento, porque a base não tem nenhum dado faltando.

Codificação das categorias. Sexo, escolaridade e estado civil são rótulos, não quantidades. Escolaridade 4 não é o dobro de escolaridade 2. Por isso usamos One-Hot, que transforma cada categoria numa coluna de sim ou não. Isso importa na prática: na nossa base, a escolaridade "outros" (código 4) tem a menor taxa de calote de todas, 5,7%, e um modelo que tratasse o código como número não conseguiria representar isso.

Já as colunas de atraso (PAY_1 a PAY_6) ficaram como número de propósito. Nelas a ordem existe de verdade: dois meses de atraso é pior que um. E a taxa de calote sobe junto com o atraso, então manter como número preserva essa informação.

Padronização. Usamos o StandardScaler, que coloca todas as colunas numéricas na mesma escala. Sem isso, o limite de crédito, que chega a um milhão, dominaria a idade, que vai até 79. Escolhemos o StandardScaler em vez do MinMaxScaler porque as colunas de dinheiro têm valores extremos e negativos, e o MinMaxScaler espremeria quase todos os clientes perto do zero. A padronização fica dentro de um Pipeline, para ser calculada só com os dados de treino e não vaziar informação do teste.

Engenharia de atributos. Criamos quatro colunas novas que resumem o histórico de seis meses num número só:

- `n_atrasos`: em quantos dos seis meses o cliente atrasou.
- `max_atraso`: o pior atraso do período.
- `util_media`: quanto da fatura ocupa o limite, em média.
- `pgto_medio`: quanto o cliente pagou, em média.

1.5.3 Implementação, treinamento e otimização

Os modelos foram treinados com a biblioteca `scikit-learn`, cada um dentro de um Pipeline junto com a padronização e o One-Hot. Nos dois modelos de classificação usamos o ajuste de peso das classes (`class_weight = balanced`), que faz o erro sobre os inadimplentes pesar mais. Sem isso o modelo percebe que dizer que ninguém dá calote já acerta a maioria e para de arriscar.

Os hiperparâmetros foram ajustados com `GridSearchCV`, que testa várias combinações e escolhe a melhor pelo F1 em validação cruzada de 5 partes, só com dados de treino.

Quadro 1: Ajuste dos modelos de classificação

Modelo	O que foi testado	Escolhido	F1 (validação)
Regressão Logística	$C = 0,01; 0,1; 1,0$	$C = 1,0$	0,525
Random Forest	profundidade 10, 16 ou sem limite; folha mínima 5 ou 20	sem limite; folha 20	0,552

Fonte: elaborado pelos autores.

Na regressão, o alvo foi a fatura de setembro (`BILL_AMT1`). Tiramos todas as colunas de setembro da entrada, porque senão o modelo estaria prevendo uma coisa que já sabe. Sobraram 20 colunas, todas do histórico de abril a agosto. Usamos exatamente a mesma divisão de treino e teste da classificação, para poder juntar as duas etapas depois.

1.5.4 Avaliação e análise de resultados

Por que essas métricas

Neste problema os erros não custam igual. Deixar passar um cliente que vai dar calote custa o dinheiro emprestado. Incomodar um cliente bom custa uma ligação. Por isso a métrica mais importante é o Recall, que mede quantos caloteiros o modelo pega. O F1 foi usado para escolher entre os modelos, porque equilibra Recall e Precision. O ROC-AUC foi usado para ver qual modelo ordena melhor os clientes por risco. A acurácia aparece só para comparação.

Comparação dos modelos de classificação

Tabela 1: Resultado no conjunto de teste (5.921 clientes)


Modelo	Acurácia	Precision	Recall	F1	ROC-AUC
Random Forest	76,9%	48,5%	59,4%	0,534	0,780
Regressão Logística	74,3%	44,6%	62,7%	0,521	0,761

Fonte: elaborado pelos autores.

O Random Forest ganhou no F1 e no ROC-AUC, por isso foi o modelo escolhido. A Regressão Logística teve Recall um pouco maior porque, no corte padrão de 0,50, ela marca mais clientes como arriscados: 31% da carteira, contra 27% do Random Forest. Quem marca mais gente pega mais caloteiros, mas também incomoda mais clientes bons. O F1 equilibra essas duas coisas, e nele o Random Forest foi melhor.

A vantagem do Random Forest vem de ele conseguir pegar combinações entre variáveis, como atraso junto com uso alto do limite. A Logística, em compensação, é mais fácil de explicar, o que num banco real também pesa.


Figura 2: Matrizes de confusão no conjunto de teste



Fonte: elaborado pelos autores.

De 1.321 clientes que deram calote no teste, o Random Forest pegou 784 e deixou passar 537, apontando 833 clientes bons como arriscados. A Logística pegou 828 e deixou passar 493, mas apontou 1.027 clientes bons.

Figura 3: Curva ROC dos dois modelos




Fonte: elaborado pelos autores.

Os dois modelos ficam bem acima da linha tracejada, que seria chutar ao acaso. A curva do Random Forest fica um pouco acima da Logística em quase toda a extensão.

Variáveis que mais pesam

Figura 4: Importância das variáveis no Random Forest



Fonte: elaborado pelos autores.

As seis variáveis mais importantes são PAY_1, max_atraso, n_atrasos, PAY_2, util_media e pgto_medio. Todas descrevem o comportamento de pagamento. Idade, sexo, escolaridade e estado civil aparecem no fim da lista. Ou seja, o que o cliente fez nos últimos meses diz muito mais sobre o risco do que quem ele é.

Quatro dessas seis colunas foram criadas por nós na engenharia de atributos, o que mostra que resumir o histórico valeu a pena.

Regressão: estimando o valor exposto

Tabela 2: Resultado dos modelos de regressão (valores em NT\$)

Modelo	Erro médio (MAE)	RMSE	R ²
Random Forest Regressor	7.566	20.021	0,920
Regressão Linear Múltipla	8.548	21.270	0,910
Polinomial de grau 2 (Ridge)	8.787	20.869	0,913

Fonte: elaborado pelos autores.

O Random Forest Regressor foi o melhor nas três medidas: errou em média NT\$ 7.566 por cliente, contra NT\$ 8.548 da Linear Múltipla e NT\$ 8.787 da Polinomial, e teve o maior R². A Polinomial ficou praticamente empatada com a Linear, o que indica que acrescentar curvas simples não ajudou muito.

Juntando as duas etapas: o valor em risco

Multiplicando a probabilidade de calote pela fatura estimada, cada cliente ganha um valor em risco em dinheiro. Ordenando por esse valor, temos a fila de prioridade da cobrança.

Tabela 3: Valor em risco na carteira de teste

Indicador	Valor
Exposição total da carteira	NT\$ 291,0 milhões
Valor em risco estimado	NT\$ 103,4 milhões (35,5%)
Calote entre os 10% do topo da fila	40,7%
Calote na carteira toda	22,3%

Fonte: elaborado pelos autores.

Entre os 10% de clientes do topo da fila, 40,7% deram calote, quase o dobro da carteira toda. Ou seja, a fila encontra caloteiros 1,8 vez mais do que escolher ao acaso, e ainda coloca na frente quem deve mais.

Análise crítica

O Random Forest foi o melhor modelo de classificação e de regressão porque o risco de crédito depende de combinações entre variáveis, e ele consegue pegar isso sozinho. A vantagem sobre a Regressão Logística, porém, foi pequena, e a Logística tem a vantagem de ser explicável. Num banco real, essa troca entre acertar um pouco mais e conseguir justificar a decisão ao cliente teria que ser pesada.

Também ficou claro que a acurácia não serve para este problema: com só 22% de calote, um modelo que não aponta ninguém já teria 78% de acurácia. Por isso decidimos pelo F1 e pelo ROC-AUC.

1.5.5 Conclusão, produto final e cronograma

Resposta ao problema

A pergunta do projeto era quais clientes exigem ação preventiva de crédito e qual valor está exposto ao risco. A resposta é uma fila de prioridade ordenada por valor em risco, em que a equipe de cobrança atende primeiro os clientes do topo. Nesse topo, a taxa de calote é quase o dobro da média, e são os clientes que mais devem.

O modelo não substitui a política de crédito nem o analista. Ele só organiza quem deve ser olhado primeiro.

Limitações

- A base é de Taiwan em 2005. Para usar no Brasil de hoje seria preciso treinar de novo com dados locais.
- Seis meses de histórico não mostram sazonalidade nem efeitos da economia.
- O valor em risco é uma aproximação didática, não a perda contábil real, porque não temos dados de recuperação da dívida nem de garantias.
- A base só tem clientes que já receberam crédito. O modelo não sabe nada sobre quem foi recusado na entrada.
- Sexo, escolaridade e estado civil estão no modelo. Mesmo pesando pouco, usar essas informações para decidir crédito é juridicamente questionável. O ideal seria treinar de novo sem elas.
- O modelo mostra associação, não causa. Nenhuma variável provoca o calote, elas só andam junto com ele.

1.5.5.1 Entregáveis

12. Documento: este relatório.
13. Código-fonte: notebook do Google Colab com a execução completa, disponível em <https://github.com/otaviobonini/machinelearningprojeto>.
14. Apresentação: slides para a defesa oral.
15. Especificações técnicas: Python 3 com pandas, numpy, scikit-learn, matplotlib, seaborn e ucimlrepo. Roda no Google Colab, sem GPU. A base é baixada automaticamente pelo pacote ucimlrepo. Semente aleatória 42.

Cronograma

Quadro 2: Cronograma do projeto

Etapas	Atividade	Semana
1	Escolha do tema, obtenção da base e pesquisa	1
2	Análise exploratória e limpeza dos dados	2
3	Preparação dos dados e criação de atributos	3
4	Treino e ajuste dos modelos de classificação	4

Etapa	Atividade	Semana
5	Regressão e valor em risco	5
6	Relatório e apresentação	6

Fonte: elaborado pelos autores.

REFERÊNCIAS

BANCO CENTRAL DO BRASIL. Estatísticas monetárias e de crédito: inadimplência do crédito livre, pessoas físicas. Brasília: BCB, jul. 2026. Disponível em: <https://www.bcb.gov.br/estatisticas/estatisticasmonetariascredito>. Acesso em: 17 set. 2026.

BREIMAN, Leo. Random Forests. *Machine Learning*, v. 45, n. 1, p. 5-32, 2001.

LESSMANN, Stefan; BAESENS, Bart; SEOW, Hsin-Vonn; THOMAS, Lyn C. Benchmarking state-of-the-art classification algorithms for credit scoring: An update of research. *European Journal of Operational Research*, v. 247, n. 1, p. 124-136, 2015.

PEDREGOSA, Fabian et al. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, v. 12, p. 2825-2830, 2011.

SERASA. 5 em cada 10 brasileiros adultos estão inadimplentes no Brasil, aponta Serasa. São Paulo: Serasa, 2026. Disponível em: <https://www.serasa.com.br/imprensa/5-em-cada-10-brasileiros-adultos-estao-inadimplentes-no-brasil-aponta-serasa/>. Acesso em: 2 out. 2026.

YEH, I-Cheng; LIEN, Che-hui. The comparisons of data mining techniques for the predictive accuracy of probability of default of credit card clients. *Expert Systems with Applications*, v. 36, n. 2, p. 2473-2480, 2009.